

P I L L D E T E C T I O N & C L A S S I F I C A T I O N

경구약제 객체 인식 모델 개발

4단계로 나눠 0.99에 도달한 15일의 기록

73개 클래스의 미세 분류 문제를, YOLOv12n 5-Fold WBF 앙상블 + EfficientNet-B3 재분류기 + EasyOCR 16입력 보정의 4단계 파이프라인으로 해결한 3주간의 의사결정 기록입니다.

A 3-week engineering report on object detection & fine-grained pill classification

T E A M

코드잇 해피 6팀

정승호 · 성치용 · 송기하 · 임동규 · 조희
원 · 전민재

P E R I O D

2026.04.20 — 05.11

3 weeks · 8 phases

S T A C K

YOLOv12n · EfficientNet-
B3

5-Fold WBF · EasyOCR 16

R E S U L T

mAP50 0.9944

73 classes · 1,093 images

00 우리는 이 프로젝트를 어떻게 살았나

대부분의 보고서는 결과부터 보여주지만, 우리는 사람의 이야기부터 꺼내고 싶었습니다. 3주간 6명이 데이터·모델·실험·웹 사이를 오가며 무엇을 배우고 어떤 마음으로 이 프로젝트를 마쳤는지 — 그 결을 먼저 읽어주시면 뒤이은 기술 기록이 더 입체적으로 다가올 것입니다.

“

의사결정의

흔적을 남긴다.

— 코드잇 해피 6팀의 협업 원칙

K E Y W O R D S

#디버깅의 흔적 #역할의 분리 #선택적 보정 #함께 배운 것

T E A M · 6 P E O P L E · 5 R O L E S



정승호 @무심

PM으로서 처음 이끄는 프로젝트라 전체 흐름과 방향을 잡기 쉽지 않았습니다. 데이터·모델·배포 각 영역을 함께 이해해야 했고, 팀원들이 친절히 설명해 주고 결정을 따라줘서 큰 힘이 됐습니다. 끝까지 함께해 준 팀원들 덕분에 행복하게 마쳤습니다.

P M



성치용 @Adam

데이터 엔지니어 역할을 처음 경험하며 데이터의 품질·구조가 모델 성능에 직접 영향을 준다는 걸 크게 느꼈습니다. 여러 팀과 협업하며 커뮤니케이션의 중요성도 배웠습니다.

D A T A
E N G



송기하 @기하

experiment lead로서 실무 속 실험의 영향이 크다는 걸 깨달았습니다. 속도와 성능을 여러 방향으로 시도해 본 점이 매력적이었고, 협업의 책임감도 함께 배웠습니다.

E X P
L E A D



임동규 @Estar0102

모델 엔지니어로서 첫 협업 — 데이터·테스트 팀 사이에서 긴밀히 협력해야 했습니다. 명확한 문제 인식과 솔루션 공유의 중요성을 체감했고, 다른 관점에서 문제를 바라보는 태도를 익혔습니다.

M O D E L
E N G



조희원 @heewon02

데이터 엔지니어로 참여하며 데이터 버전이 바뀔 때마다 모델 성능이 달라지는 것을 직접 보며 좋은 데이터의 중요성을 실감했습니다. 혼자서는 얻을 수 없는 경험과 배움을 얻었습니다.

D A T A
E N G



전민재 @minjaejeon

웹 개발자로서 '사용자 경험'을 깊이 고민해 본 소중한 시간. 다른 직무 팀원들과 기술적으로 소통하며 시야를 넓힐 수 있었습니다.

W E B
D E V

— 읽는 흐름

P A G E S

20

20 pages

S E C T I O N S

07

07 sections

R E A D T I M E

14 min

편하게 한 호흡

D E C I S I O N P O I N T S

6 calls

6 의사결정 흔적

본 보고서는 ‘우리가 어떻게 0.99에 도달했는가’보다 ‘왜 그 길을 골랐는가’를 더 길게 적어둔 글입니다. 의사결정의 흔적을 따라 읽어주세요.

EP	우리는 이 프로젝트를 어떻게 살았나	PROLOGUE	p. 02
01	232장에서 1,093장으로	DATA FOUNDATION	p. 04
02	단일 모델로는 안 됐습니다	PIPELINE ARCHITECTURE	p. 05
03	v0에서 v4+까지 6번 돌아왔습니다	ARCHITECTURE EVOLUTION	p. 11
—	0.25 & 0.85 — 두 임계값의 비밀	INTERLUDE	p. 13
04	한 값이 아닌 묶음의 균형	HYPERPARAMETER TUNING	p. 14
05	확신이 또렷해졌습니다	REAL-WORLD RESULTS	p. 15
06	복약 봉투를 잃어버린 사람에게	CONCLUSION & IMPACT	p. 17

D E S I G N P R I N C I P L E S · 3 a x e s

A X I S 0 1

왜

WHY

의사결정

결과 한 줄보다 그 길을 고른 이유를 더 길게 적었습니다.

A X I S 0 2

어떻게

HOW

검증

mAP 0.99에 도달하기까지의 6번의 의사결정과 10번의 디버깅.

A X I S 0 3

무엇이

WHAT

남았나

“다음 프로젝트에서도 이 방식으로 풀 수 있다”는 자신감.

G L O S S A R Y · 자주 등장하는 약어

W B F

Weighted Box Fusion

여러 모델 박스를 가중 평균

N M S

Non-Max Suppression

겹친 박스 중 신뢰도 낮은 것 제거

O O D

Out-of-Distribution

학습 분포에 없거나 부족한 데이터

M A P

mean Avg. Precision

객체 검출 표준 평가 지표


01 232장에서 1,093장으로

DATA · CLASS · OOD

CHAPTER OVERVIEW

원본 데이터셋 232장만으로는 73개 클래스 미세 분류에 부족했습니다. 약학정보원·AI Hub 기반 합성 증강 861장과 OOD 카탈로그 20종을 더해, 11번의 데이터 사이클을 거쳐 최종 1,093장의 학습 데이터를 만들었습니다.

DATA COMPOSITION · 3 sources




SCALE AT A GLANCE · 4 indicators

CLASSES	AVG / CLASS	TEST IMAGES	BBOX TOTAL
73 최종 학습 클래스	15장 클래스당 평균 학습	842 Kaggle 채점셋	3,840 총 바운딩 박스

SOURCE BREAKDOWN · 데이터 진화 v1 → v11

데이터셋 진화 — v1~v11에 걸친 클래스·이미지 수 변화



클래스 수(파랑)와 학습 이미지 수(분홍)의 변화 — v8~v9에서 합성 증강이 본격화되며 이미지가 4배 가까이 증가.

한 줄 요약 — 핵심 난이도는 데이터 양이 아니라 도메인 특성. 색상·형태·크기가 거의 동일한 클래스 간 미세 분류, 표면 각인 가독성, 클래스 불균형, 모서리 배경 곡면 토막 — 4가지 도메인 특성이 4단계 파이프라인을 만든 이유.

02 단일 모델로는 안 됐습니다

4 - S T A G E S E L E C T I V E C O R R E C T I O N

P I P E L I N E O V E R V I E W

“쉬운 박스는 빠르게 통과시키고, 어려운 박스만 두 번 더 검증한다.” $\text{conf} \geq 0.85$ 는 직접 출력, $0.25 \leq \text{conf} < 0.85$ 는 EfficientNet-B3 + EasyOCR 16입력으로 보정, $\text{conf} < 0.25$ 는 제거 — 모든 결정이 이 한 줄로 환원됩니다.

P I P E L I N E D I A G R A M · 4 - s t a g e f l o w



STAGE 1 → 후처리-STAGE 2-OCR (병렬) → 출력의 4단계 흐름.

C O R E I N N O V A T I O N S · 4 c h a n g e s

0 1 S T A G E 1

5-Fold WBF

fold 동의 박스 신뢰도 상승

0 2 P O S T - P R O C

필터 2중

꼭지점 + 중복 NMS

0 3 S T A G E 2

EfficientNet-B3

conf<0.85만 재분류


0 4 O C R

16 inputs

4방향 × 4전처리

2-1 신뢰도 임계값 0.25 & 0.85

THRESHOLD DESIGN




① YOLO 검출 임계값 — 0.25

YOLO 단일 모델 F1 최적값은 0.827이지만, 이 파이프라인에서 YOLO의 역할은 “최대한 많은 후보 bbox를 만들어내는 1차 탐지기”입니다. 0.25를 채택해 후보 박스를 최대화하고 배경 오탐은 별도 후처리로 제거합니다.


② Stage 2-OCR 적용 임계값 — 0.85

Precision 곡선에서 $\text{conf} \geq 0.85$ 구간은 1에 가까운 정밀도를 보입니다. 그 이상은 추가 보정 없이 출력하고 $0.25 \leq \text{conf} < 0.85$ 구간만 Stage 2-OCR로 보정합니다.



2-2 8단계 발전 타임라인

v 0 → v 4 +



04.20 ~ 05.04 — 모델 6번 갈아탔고, 매 단계마다 명확한 사유가 있었습니다.

VERSION RECAP · 6 phases

V 0	V 1	V 2	V 3	V 4	V 4 +
YOLOv11s	5-Fold WBF	+ 후처리 필터	EasyOCR + v12n	EfficientNet-B3	v11 안정화
단일 Fold 베이스라인	교차검증 + 가중 병합	꼭지점 / 중복 박스 제거	각인 보정 + 모델 업그레이드	2-Stage 재분류기 도입	OOM 해결 + 배포 완료

2-3 버전별 핵심 변경

W H Y E A C H S W I T C H

v 0 · B A S E L I N E



v 1 · 5 - F O L D W B F

단일 모델의 과적합과 불균형 한계를 교차 검증과 가중 병합으로 해결합니다. 약 1,000장 규모에서 K=5는 가장 균형 잡힌 선택입니다. WBF는 NMS와 달리 "겹치는 박스 중 하나를 제거"하는 대신 "모든 박스를 가중 평균"합니다.

I M G S Z	B A T C H	C L S	W B F I O U
832	8	1.5	0.5
YOLO stride 32 배수	RTX 4070 12GB OOM 회피	분류 손실 가중치 강화	병합 임계값

v 2 · P O S T - P R O C F I L T E R S · 2 s y s t e m s

F I L T E R 1	F I L T E R 2
filter_corner_boxes	filter_overlapping_boxes
5px · 2변 접면	IoU > 0.45
꼭지점 오탐 제거	중복 박스 제거
이미지 모서리 꼭면 → 알약 오인 방지	클래스 무관 Greedy NMS

2-4 v3·v4 — OCR과 2-Stage 재분류기 BACKBONE & RECLASSIFIER

v 3 · O C R + Y O L O v 1 2 n

YOLO는 색상·형태만 보기 때문에 외관은 동일하나 각인이 다른 약품을 구분할 수 없습니다. v3에서는 신뢰도 0.85 미만 알약에 EasyOCR을 적용해 각인을 인식합니다. 동시에 YOLOv12n으로 전환 — R-ELAN 블록 기반 특징 추출기로 작고 세밀한 특징을 더 잘 잡습니다.

대표 사례 · 게루삼염정

알드린정과 외형이 거의 동일하지만 각인만 다른 케이스를 EasyOCR 보정으로 식별 성공. 단, 각인이 흐리거나 없는 약품은 여전히 오분류 → v4 2-Stage 도입의 동기.

v 4 · 2 - S T A G E C L A S S I F I E R · E f f i c i e n t N e t - B 3

CONF < 0.25

제거

배경 오탐

95%↑

무조건 제거가 최선

0.25 ~ 0.85

Stage 2 + OCR

$\gamma=2.0$ · 16입력

재분류

정밀도 가장 큰 보정 효과

CONF ≥ 0.85

직접 출력

오분류율 < 2%

생략

추가 비용 대비 효과 낮음

STAGE 2 CONFIGURATION

PRETRAINED	INPUT SIZE	BATCH SIZE	OPTIMIZER	LOSS
ImageNet 1k	224 × 224 bbox crop · resize	32	AdamW wd = 0.05	FocalLoss $\gamma=2.0$ · LS=0.1

2-5 Stage 2 보정 결과

CASE STUDIES

EfficientNet-B3와 EasyOCR이 실제로 어떤 박스를 어떻게 보정했는지 — 4가지 보정 패턴: 신뢰도 상승, 오분류 교정, OCR 향상, OCR 교정.

보정 분류	TEST ID	보정 전	보정 후
STAGE 2 신뢰도 상승	1030	아토젯정 0.79	아토젯정 0.95
	1105	아토젯정 0.85	아토젯정 0.98
	1214	메가파워정 0.81	메가파워정 0.93
STAGE 2 오분류 교정	1030	아토젯정 0.66	트윈스타정 0.85
	1051	뉴로메드정 0.55	타이레놀정 0.77
	1003 외 3건	써스펜 < 0.95	타이레놀정 1.00
OCR 신뢰도 향상	1173 외 2건	에어탈정 < 0.94	에어탈정 1.00
	1050 외 3건	게루삼엠정 < 0.98	게루삼엠정 0.99~1.00
	1213	써스펜 0.94	타이레놀정 0.98
OCR 오분류 교정	1312	알드린정 0.70	게루삼엠정 0.96

FOUR CORRECTION PATTERNS · 4 m o d e s

① C O N F I D E N C E ↑	② R E C L A S S I F Y	③ O C R B O O S T	④ O C R F I X
신뢰도 상승	오분류 교정	OCR 신뢰도	OCR 교정
Stage 2 동일 정답	Stage 2 정답 변경	EasyOCR 16입력	각인 한 글자
+0.10	0.66→0.85	→1.00	0.70→0.96
같은 답을 더 확실하게 만들	외관 유사 케이스에서 정답 자체가 바뀜	각인 또렷한 케이스에서 1.00 수렴	YOLO-EfficientNet도 못 잡은 케이스를 뒤집음

STAGE 2 LIMITATIONS · 남 은 한 계

4단계 파이프라인으로도 끝까지 잡지 못한 케이스가 있습니다. 표면이 심하게 마모된 알약, 각인이 거의 사라진 약품, 그리고 학습 데이터에 한 번도 등장하지 않은 새 약품 — 이런 케이스는 데이터 자체의 보강이 답입니다.

대응 방향

v8~v11에서 합성 증강 + OOD 카탈로그(20종)로 점진적으로 좁혀왔으며, 향후 약학정보원 API 연동으로 신규 약물 자동 학습을 검토할 수 있습니다.

CHAPTER 02 · R E C A P · 4 t a k e a w a y s

01 S T R U C T U R E	02 T H R E S H O L D	03 S A M P L E S	04 P A T T E R N S
4단계	0.25 / 0.85	7+ 사례	4가지
선택적 보정 파이프라인	관용·확신의 분리	실제 보정 결과 확인	보정 모드의 분류

“쉬운 박스는 빠르게, 어려운 박스만 두 번 더 검증한다.”

03 v0에서 v4+ 까지 6번 돌아왔습니다

BUG FIX × 10

CHAPTER OVERVIEW

15일 안에서 모델 성능보다 “세팅값과 인프라가 만든 함정”을 잡아낸 비중이 컸습니다. 10개의 버그 = 10개의 의사결정 흔적입니다.

10건의 버그 — 절반 이상이 모델 자체가 아니라 세팅·후처리에서 발생

학습 세팅
(OOM·patience·cls)

BUG-1, 2, 3, 10

4건

후처리 / 데이터
(필터·증강·OCR)

BUG-4, 5, 6, 9

4건

모델 / 아키텍처
(분류기·회전)

BUG-7, 8

2건

10건의 버그를 카테고리별로 분류 — 학습 세팅 4건, 후처리/데이터 4건, 모델/아키텍처 2건.

BUG TIMELINE · 10 fixes

ID	단 계	증 상 / 원 인	해 결
BUG-1	v0~v1	imgsz 1024 + batch 2 → 5-Fold OOM	imgsz 832 / batch 8
BUG-2	v0~v1	patience=0 → early stopping 비활성	patience=30
BUG-3	v1	cls=0.5 외관 유사 알약 구분 부족	cls=1.5
BUG-4	v2	모서리 배경 곡면 → 알약 오염	filter_corner_boxes()
BUG-5	v2	동일 위치 중복 bbox	filter_overlapping_boxes()
BUG-6	v3	게루삼염정 식별 불가	EasyOCR + code_mapping
BUG-7	v4	rotation_info 세로 SK → 가로 U	물리 회전 4방향 OCR
BUG-8	v4	conf 0.25~0.85 정밀도 저하	EfficientNet-B3 2-Stage
BUG-9	v3~v4	mosaic이 작은 알약 특징 왜곡	close_mosaic=30
BUG-10	v4+	v10/v11 데이터 확장 후 OOM 재발	PNG→JPG 경량화 -83%

10건 중 절반(BUG-1·2·3·5·9·10)은 모델 자체가 아니라 학습 세팅·후처리 파라미터에서 발생했습니다. “모델 교체”보다 “현재 모델이 왜 이 케이스를 틀리는가”를 끝까지 추적하는 디버깅 태도가 성능 향상의 절반 이상을 차지했습니다.

교훈 — “모델은 죄가 없다. 데이터·세팅·환경이 모델을 뒤흔친다.”

두 자리 숫자가 만든 한 가지 철학.

Y O L O 검 출

0.25

관용의 임계값

MAX RECALL

“가능한 한 많은 알약 후보를 만들어내라.” 배경 오탐은 후처리가 정리한다.

S T A G E 2 분 기

0.85

확신의 임계값

MAX PRECISION

“이미 충분히 확신할 때만 그대로 통과시킨다.” 모호한 박스만 보정한다.

단일 임계값(예: F1 최적값 0.827)은 “이 점수 이상은 출력, 이하는 버린다”라는 이분법입니다. 그러나 우리 도메인은 모호한 회색 지대(0.25~0.85)가 가장 흥미로운 영역이었습니다. 이 회색 지대를 버리지 않고 두 번째 모델로 보강하기 위해 두 임계값이 필요했습니다.

한 자리 숫자가 아닌 ‘역할의 분리’.

T W O - N U M B E R R E A S O N I N G · 3 t h i n k i n g p o i n t s

① W H Y N O T S I N G L E

단일 임계값

F1 최적값 0.827

이분법

“이 이상은 출력, 이하는 버린다.” 회색 지대를 통째로 잃어버리는 단순함.

② G R E Y Z O N E

0.25 ~ 0.85

모호한 60% 구간

재검토

가장 흥미로운 박스가 모인 구간. 두 번째 모델로 보강할 가치.

③ R O L E S P L I T

역할의 분리

0.25 + 0.85

균형점

관용(많이 만들기) + 확신(잘 통과시키기). 두 숫자가 함께 있어야 균형.

I M P A C T O F T H E T W O N U M B E R S · 무 엇 이 달 라 졌 나

B B O X 후 보 수

+220%

0.827 → 0.25로 낮춰 후보 박스 수 약 3배 확보

재 분 류 적 용 비 율

37%

전체 박스 중 0.25~0.85 구간이 재분류 대상

직 접 통 과 율

63%

conf ≥ 0.85 박스는 그대로 출력 — 추론 속도 확보

최 종 M A P 5 0

0.9944

두 임계값 + 4단계 파이프라인의 결과

“단일 임계값은 이분법이지만, **두 임계값은 의사결정 구조다.**”

04 한 값이 아닌 묶음의 균형

8 P A R A M S · 4 A X E S

T U N I N G P H I L O S O P H Y

단일 파라미터 튜닝이 아닌, '해상도·손실 가중치·증강 전략·Early Stopping'을 한 묶음으로 조정한 것이 성능 향상의 핵심이었습니다.
어느 한 값을 정답에 맞춘 것이 아니라 '파라미터 묶음의 균형점'을 찾는 작업이었습니다.

K E Y H Y P E R P A R A M E T E R S · 8 c h a n g e s

P A R A M E T E R	B E F O R E	A F T E R	W H Y
imgsz	1,024	832	stride 32 배수 · 각인 가독 최소
batch	2	8	RTX 4070 12GB 5-Fold OOM 방지
epochs / patience	300 / 0	150 / 30	Early stopping 활성화
cls	0.5	1.5	분류 손실 가중치 강화
degrees	15	90	방향 무관 학습
flipud	0.0	0.5	상하 반전 증강 추가
close_mosaic	15	30	마지막 30 에폭 mosaic 끄기
mosaic / mixup	1.0 / 0.1	0.8 / 0.05	강도 완화 · 수렴 안정화

4 T U N I N G A X E S

0 1 R E S O L U T I O N

imgsz

각인 vs VRAM

832

stride 32 배수의 최소 해상도

0 2 C L S W E I G H T

cls

위치 vs 분류

1.5

분류 쪽 무게중심 이동

0 3 A U G M E N T

degrees

방향 무관

90°

회전 증강 강화

0 4 C O N V E R G E

patience

과적합 vs 학습


30

Early stopping 활성화

05 확신이 또렷해졌습니다

C A S E × 3

단계마다 또렷해진 “모델의 확신” — 5단계 누적 효과



v0(0.62)에서 출발한 신뢰도 중앙값은 5단계의 누적을 거쳐 0.96까지 상승.

C A S E 0 1 · 학습 데이터 회전 전 처리

가로로 누운 놀텍정은 잘 탐지하지만 세로로 선 놀텍정은 전혀 탐지하지 못하는 ‘방향 편향’이 발견되었습니다. 학습 데이터에 특정 각도만 포함되어 방향 불변성이 학습되지 않았기 때문.

해결 · degrees=90

알약은 원형·타원형이므로 어떤 방향에서 촬영해도 동일하게 인식되어야 합니다. 0°·90°·180°·270° 전 방향 커버.

C A S E 0 2 · O O D 데이터 검출

알약 표면이 지저분해 신뢰도가 낮아 bbox조차 탐지되지 않던 케이스를 합성 증강과 클래스 추가, 2-Stage 적용으로 검출에 성공. 특히 v11에서 코싹엘정을 추가 수집·합성한 후 미인식 문제가 해소.

대응 절차

① 미인식 식별 → ② 데이터 수집 → ③ 합성 증강 → ④ 카탈로그 갱신
→ ⑤ 검증

C A S E 0 3 · 단계별 누적 효과

V 0	+ W B F	+ 후 처 리	+ O C R	+ B 3
0.62	0.78	0.83	0.91	0.96
단일 모델	fold 동의	필터 2중	각인 보정	재분류기

06 복약 봉투를 잃어버린 사람에게

m A P 0.99 너머

의료 사고 예방, 디지털 헬스케어 연동, 약국·병원 자동화로 이어지는 비즈니스 가치. 단일 모델로는 도달할 수 없는 신뢰의 영역.

F I N A L M E T R I C S · 최 종 학 습 성 과

Y O L O V 1 2 N

0.9944

mAP50 (5-Fold 평균)

Y O L O V 1 2 N

0.9847

mAP50-95

E F F I C I E N T N E T - B 3

0.9980

val_acc

O O D C A T A L O G

20중

기존 17 + 신규 3

K E Y A C H I E V E M E N T S · 5 r e s u l t s

01. 99.9%

테스트 데이터 검출 알약 3,229개 중 3,326개 클래스 예측 성공.

02. 4-stage

WBF + 후처리 + 2-Stage + OCR로 단일 모델 대비 오분류율 대폭 감소.

03. 10 BUGS

15일 내 반복 개선으로 메모리·속도·정확도 모두 안정화.

04. 861 SYNTHETIC

합성 증강 861장으로 원본 232장의 데이터 부족 문제 해결.

05. -83%

PNG → JPG 변환으로 패키지 용량 83% 절감, 배포 효율 확보.

B U S I N E S S I M P A C T · 4 a r e a s

0 1 의 료

복약 오류 방지

오투약 사전 차단

CARE

다품목 복약 환자에 직접 가치

0 2 D - H E A L T H

실시간 식별 앱

카메라 한 번

APP

약 봉투 없이 즉시 약명 확인

0 3 A U T O M A T I O N

약국·병원 자동화

대조 + 재고

OPS

외형 검수를 시스템이 보조

0 4 P L A T F O R M

확장 가능 설계

데이터·클래스 확장만으로

SCALE

파이프라인 자체를 재활용

“이 프로젝트는 mAP 0.99짜리 모델을 만든 경험이 아니라, 6명이 같은 문제를 다른 각도로 바라보며 의사결정을 합쳐가는 경험이었습니다.”

— 코드잇 해피 6팀 회고